2026年度　行動経済学

Session 3-2　学習モデル(Learning Models)と確率的進化ゲーム

今日のテーマ

QRE も Level-k も、意思決定を静的な現象として扱ってきた。QRE は均衡状態における確率的選択を、Level-k は初期行動における限定的推論を描いたが、いずれも「経験を通じて行動がどう変わるか」という動学的側面を扱っていない。

現実には、人は同じような状況に繰り返し直面し、過去の経験から学び、将来の行動を適応させていく。
　同じ相手と何度もじゃんけんをする、市場で競合他社と繰り返し価格競争をする、など。

今回

1. 強化学習(Reinforcement Learning)
2. 信念学習(Belief Learning)と仮想プレー(Fictitious Play)
3. 統合モデル：EWA 学習
4. 学習モデルへの問い：人は何を学んでいるのか
5. 確率的進化ゲームと均衡選択

強化学習(Reinforcement Learning)

学習への最も単純で直観的なアプローチ。
中核にあるのは心理学の「効果の法則(law of effect)」である。
「良い結果をもたらした行動は繰り返されやすく、悪い結果をもたらした行動は繰り返されにくい」

強化学習モデルは、プレイヤーをあまり洗練されていない意思決定者として描く。
- 相手の利得や思考過程を推論しない
- 自分の過去の行動と、その結果得られた利得の履歴だけに注目する
- 過去に高い利得をもたらした戦略を再選択する確率を高める

もともとは動物行動を説明するために発展した考え方である。心理学者 B. F. Skinner の「スキナー箱」の実験が有名で、箱の中のラットはレバーを押すと餌が出ることを経験すると、レバーを押す頻度を増やす。強化学習はこの試行錯誤の過程を数学的に定式化する。

強化学習の定式化（Erev and Roth, 1998）

① 魅力度(attraction)の更新

プレイヤーは各戦略 j に対して魅力度 $a_j(t)$ という数値をもつ。これはその戦略が過去にどれだけうまくいったかの累積スコアと考えられる。

時点 t に戦略 k を選び、利得 x_k を得たとする。次期の魅力度は

$$a_j(t+1) = (1-\gamma)\, a_j(t) + RF(x_k) \qquad (j = k\text{: 選んだ戦略})$$

$$a_j(t+1) = (1-\gamma)\, a_j(t) \qquad (j \neq k\text{: 選ばなかった戦略})$$

RF(x_k) は強化関数(reinforcement function)。得られた利得を魅力度の更新量に変換する。最も単純な形は RF(x_k) = x_k。

γ は忘却パラメータ(forgetting parameter)で 0 と 1 の間の値。過去の経験がどれだけ速く忘れられるかを表す。

② 確率的選択ルール

時点 t に戦略 k を選ぶ確率は、魅力度の相対的な大きさで決まる。

$$p_k(t) = \frac{a_k(t)}{\sum_j a_j\,(t)}$$

強化学習の実証的な意義

Erev and Roth (1998) は、このきわめて単純なモデルが、いくつかの代表的なゲームにおける人間被験者の実際の行動を、ナッシュ均衡の予測よりもよく説明できることを示した。

人間は、常に合理的な均衡計算を行っているのではなく、もっと単純な試行錯誤によって学習しているのかもしれない。

ただし強化学習は内省的(introspective)なモデルである。自分の経験だけを見て、相手が何をしているかを見ていない。

→ 相手を観察するアプローチが信念学習である。

信念学習と仮想プレー(Fictitious Play)

信念学習(Belief Learning)は、プレイヤーが相手の行動を観察し、「相手が将来どう行動するか」についての信念を形成・更新し、その信念に対する最適反応を取る、とモデル化する。

このカテゴリーで最も古典的かつ有名なのが、Brown (1951) が提唱した仮想プレー(Fictitious Play)である。

プレイヤーは「相手は過去のプレー頻度に完全に比例した確率で次の手を選ぶ」と信じているかのように振る舞う。

定式化

① 相手のプレー頻度の記録　$F_{-i}{}^{k}(t)$：相手が過去に戦略 k を選んだ回数

② 信念形成

$$B_{-i}^{k}(t) = \frac{F_{-i}^{k}(t)}{\sum_j F_{-i}^{j}(t)}$$

③ 期待効用の計算

$$E_i^j(t) = \sum_k u_i\left(s_i^j, s_{-i}^k\right) B_{-i}^k(t)$$

④ 最適反応の選択　最も単純な形では期待効用を最大にする純戦略を選ぶ。より現実的なモデル（確率的仮想プレー）では、QRE で見たロジット選択ルールを用いて確率的に選ぶと仮定する。

どちらのモデルが優れているか

Feltovich (2000 Econometrica) は複数のゲーム実験のデータを分析し、強化学習と信念学習の性能を比較した。

Erev & RothのMatching Pennies、Ochsの2×2、Van Huyck et al.、Mookherjee & Sopher
⇒ Matching PenniesではREが強い。Ochsでは基準によってBAが勝つ。Van HuyckではBAが明確に強い。Mookherjee–Sopherでは評価基準による。ただしいずれもNash均衡よりは予測力はある。

結果

どちらのモデルもナッシュ均衡よりはるかに高い予測力をもつ。
しかし、どちらが優れているかはゲームのタイプに依存する。
⇒ 学習はしているが、何を学習しているかの識別は難しい。

強化学習と信念学習は、人間の学習の異なる側面をとらえている。
人は学習するとき、この両方の要素を考慮しているのではないか。
→ 統合モデルへ

統合モデル：EWA 学習

Camerer and Ho (1999) が提唱したEWA (Experience-Weighted Attraction) モデルは、2つのアプローチを統合したハイブリッド・モデルである。

中核となるアイデアは、魅力度の更新ルールにある。

強化学習では、選んだ戦略の魅力度だけが更新された。

EWA では、選ばなかった戦略の魅力度も、「もし選んでいたら得られたはずの利得(foregone payoffs)」に基づいて更新される。

EWA はより一般的で柔軟な学習モデルであり、パラメータの値を変えることで、純粋な強化学習モデルも純粋な信念学習モデルも特殊ケースとして再現できる。

さらに Camerer, Ho, and Chong (2002) は、学習者が他のプレイヤーもまた学習者であるとモデル化するSophisticated EWA モデルを提唱した。プレイヤーが他者の学習を戦略的に「教育」したり先読みしたりできるため、なぜ均衡への収束が速いことがあるのか、といった現象を説明できる。

統合モデル：EWA 学習

1. Experience Weight の更新

$$N(t) = \rho N(t-1) + 1$$

2. Attraction の更新

$$A_i^j(t) = \frac{\phi N(t-1) A_i^j(t-1) + \left[\delta + (1-\delta) I\left(s_i^j, s_i(t)\right)\right] \pi_i\left(s_i^j, s_{-i}(t)\right)}{N(t)}$$

EWAの特徴：実際に選んだ戦略だけでなく、選ばなかった戦略の仮想利得も学習に取り込む。

3. Logit による戦略選択

$$P_i^j(t+1) = \frac{\exp\left(\lambda A_i^j(t)\right)}{\sum_{k=1}^{m_i} \exp\left(\lambda A_i^k(t)\right)}$$

記号	意味
ρ	過去の experience weight をどれだけ保持するか
ϕ	過去の attraction をどれだけ保持するか
δ	未選択戦略の foregone payoff をどれだけ反映するか
λ	attraction への反応の強さ（大きいほど高い attraction に集中）
N(0)	初期経験量（experience weight の初期値）
A_i^j(0)	戦略 j の初期 attraction
I(·)	実際に戦略 j を選んだとき1，それ以外は 0 の指示関数

統合モデル：EWA 学習

EWA は、強化学習と信念学習を1つの更新式で統合したモデルとして理解できる。

モデル	主なパラメータ制約	何を学習するか	解釈
Reinforcement Learning	$\delta = 0$（典型例では $\rho = 0$ ）	実際に選んだ戦略の実現利得のみ	選択した戦略だけが強化される。未選択戦略の仮想利得は使わない。
Belief Learning (Weighted Fictitious Play)	$\delta = 1, \rho = \varphi$	すべての戦略の仮想利得	「もしその戦略を選んでいたら」の利得も完全に反映する。
一般の EWA	$0 \leq \delta \leq 1$、ρ と φ は自由	実現利得と仮想利得の両方	RL と BL の中間に位置し、両者を滑らかにつなぐ。

δ が 0 に近いほど「実際に選んだ戦略の強化」に近づき、δ が 1 に近いほど「すべての戦略の期待利得比較」に近づく。

学習モデルの識別能力への疑問

識別に関する疑問

Salmon (2001, Econometrica)はMonte Carlo simulationによって学習モデルの識別可能性を検証した。unique mixed-strategy equilibriumを持つconstant-sum normal-form gamesにおいて、特定の学習モデル（EWAでパラメータを変える）を使って疑似データを生成して、それを書く学習モデルにfittingする。

どのlearning ruleがデータを生成したかを、実際にeconometric estimationで識別できるのか？

⇒ できない。たとえば強化学習モデルを使って生成したデータを一番よく説明するのが信念学習モデルということが起こる。

推定上の問題も指摘されている。

Wilcox (2006, Econometrica)は、個人間の異質性を無視した pooled estimation では、Reinforcement Learning における「過去に選択した戦略の強化」が見かけ上支持される方向にバイアスが生じうる。

⇒ なぜなら真の学習ルールが Belief Learning であっても、反応係数などに個人差がある場合、過去の選択はその個人差に関する情報を含むから。個人差を考慮する Random Coefficient Model によって、このバイアスは大幅に軽減されうるが、その完全な除去や真の学習メカニズムの識別が常に保証されるわけではない。

学習モデルへの問い：公共財ゲーム

学習モデルは、プレイヤーがナッシュ均衡へ収束していく過程を記述する強力な道具である。しかし Andreoni (1988) や Croson (1996) による公共財ゲーム(Public Goods Game)の実験は、この単純な解釈に重要な問いを投げかける。

ゲームの構造

n人のプレイヤーが初期保有 E を与えられる。各人は「公共口座」にいくら c_i を拠出するかを選ぶ。残り $E - c_i$ は自分のものになる。

実験者は公共口座の総額 $C = \Sigma c_j$ を a 倍（$a > 1$）し、全員に等分する。したがって最終利得は

$$\pi_i = (E - c_i) + \frac{a}{n} C$$

一人当たり限界収益(MPCR) a/n は通常 1 未満に設定される。

社会的最適：$a > 1$ なので、全員が全額拠出すると総余剰が最大になる。

ナッシュ均衡：MPCR < 1 なので、拠出しないことが常に個人的に最適。支配戦略はゼロ拠出、すなわちフリーライドである。

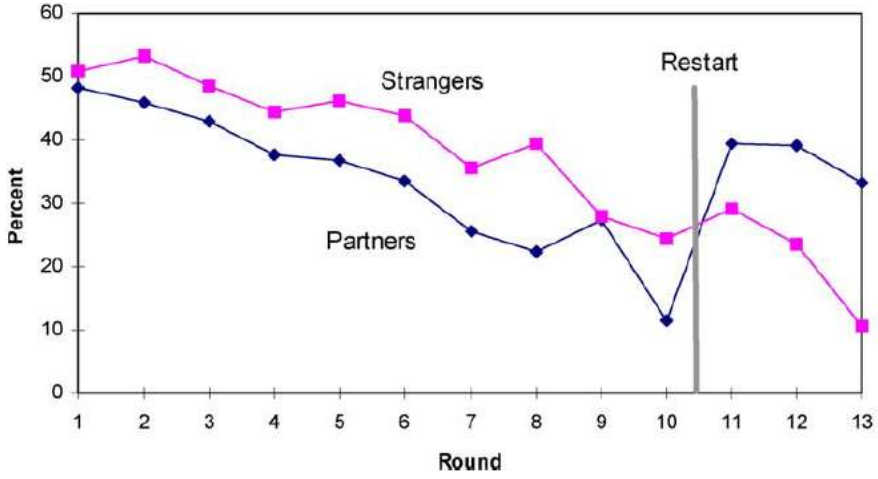
学習のパラドクス：Restart 効果

このゲームを実験で繰り返しプレーさせると、当初は高かった拠出水準がラウンドを追うごとに低下していく。
→ 「フリーライドが最適だ」と経験から学び、ナッシュ均衡に収束していると解釈できる。

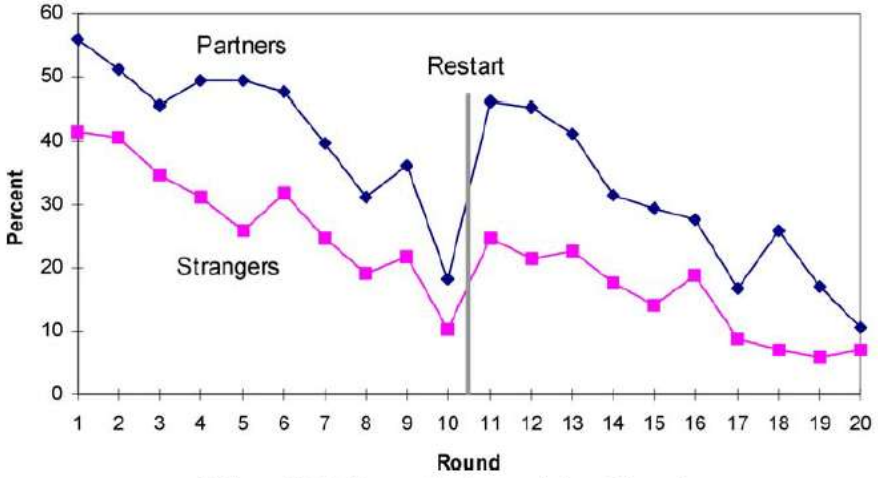
しかし Andreoni らは巧妙な工夫を加えた。
10ラウンド後にグループのメンバーをシャッフルし、新しい相手とゲームを続けさせた（Restart 条件）。
驚くべきことに、ほぼゼロまで低下していた協調水準が、当初の高い水準まで回復した。

この結果は、学習についての単純な見方に疑問を投げかける。
もしプレイヤーが「このゲームのナッシュ均衡は非協調である」という普遍的な事実を本当に学習したのなら、相手が誰であろうと非協調を続けたはずである。
協調が回復したという事実は、プレイヤーが学んでいたのはゲームの抽象的な構造ではなく、特定のグループ内で形成された規範や信頼、あるいは目の前の相手の「タイプ」といった文脈固有の要因だったことを示唆する。

※補足　公共財供給ゲーム　繰り返した結果



A. Andreoni (1988): Percent of endowment in the public good



B. Croson (1996): Percent of endowment in the public good

学習モデルの評価

評価されている点

人間の学習という動学的過程を、ゲーム理論の均衡分析の中に持ち込んだこと。

しかし、その発展の勢いはその後失われた。

考えられる理由

① 人間の学習のモデルとして恣意的すぎる
② 認知階層モデルと同様、均衡モデルではないため、予測が文脈依存的になる
③ 他のモデルより自由パラメータが多く、頑健性に欠けやすい

確率的進化ゲーム(Stochastic Evolutionary Game Theory)

限定合理的なプレイヤーが、学習と試行錯誤の過程を通じて繰り返し相互作用するとき、長期的にはどのような状態が定着するのか。

このモデルは、プレイヤーの動学的な学習過程に、まれな「誤り」や「突然変異」といったノイズの要素を導入することで、膨大な時間スケールにおいてどの均衡が生き残りやすいかを予測する。

確率的安定均衡(Stochastically Stable Equilibrium, SSE)

「長期均衡(Long Run Equilibrium)」「安定的慣習(Stable Convention)」とも呼ばれる。学習と試行錯誤の過程がまれなノイズによって撹乱されるとき、社会が超長期的に最も多くの時間を過ごすことになる状態。

SSE が選ばれるメカニズム

① 進化・学習過程（決定論的動学）

プレイヤーは繰り返しゲームをプレーし、より成功しているプレイヤーの戦略を模倣したり、自分の経験から最適戦略を学んだりする。ただしこの過程だけでは、到達する均衡は初期状態に依存してしまう（経路依存性, path dependence の問題）。

② 突然変異の導入

この決定論的過程に確率的なノイズを加える。プレイヤーはごく小さな確率で、利得と無関係にランダムな行動を選びうる。「誤り」「気まぐれ」「新戦略の実験」と解釈できる。

③ 状態間の遷移

突然変異があるため、社会は単一の均衡状態に永久に固定されない。学習過程は各ナッシュ均衡のまわりに吸引域(basin of attraction)を形成するが、まれな突然変異が同時に十分な数だけ起これば、別の吸引域へ「ジャンプ」できる。

④ 長期の均衡選択

吸引域から脱出するのに必要な同時突然変異の最小数は、均衡ごとに異なる。SSE とは、脱出に最も多くの突然変異（＝最も起こりにくい事象）を必要とする均衡である。いったんこの最も安定な状態に落ちると脱出は極めて難しく、社会は超長期のほぼすべての時間をそこで過ごす。

※ KMRの詳細は Session3-2KMR付録.ppxを参照

KMR (1993)：スタグハント・ゲーム

Kandori, Mailath, and Rob (1993)（以下 KMR）は、この確率的進化過程が、複数均衡をもつコーディネーションゲームにおいてリスク支配(risk-dominant)均衡を選択することを示した。

	B：鹿を狩る	**B：兎を狩る**
A：鹿を狩る	(4, 4)	(0, 3)
A：兎を狩る	(3, 0)	(2, 2)

純戦略のナッシュ均衡は（鹿, 鹿）と（兎, 兎）の2つ。

（鹿, 鹿）は利得支配(payoff-dominant)均衡 ― より高い利得をもたらす

（兎, 兎）はリスク支配(risk-dominant)均衡 ― より安全な帰結

突然変異がなければ、社会は初期条件に応じてどちらかの吸引域に収束する。

補論：リスク支配(Risk Dominance)

Harsanyi と Selten が提唱した、複数のナッシュ均衡をもつゲームのための均衡選択基準。

利得支配(Payoff Dominance)均衡

他のどの均衡よりも全プレイヤーに高い利得をもたらす均衡。「全員がうまく協調できたときの最善の帰結」。

リスク支配(Risk Dominance)均衡

協調の失敗を考慮したときにより安全な均衡。「失敗のリスクを踏まえたより慎重な選択」。

	プレイヤー2：C	プレイヤー2：D
プレイヤー1：A	(a, w)	(b, x)
プレイヤー1：B	(c, y)	(d, z)

(A, C) と (B, D) がともに純戦略ナッシュ均衡であるとき、(A, C) が (B, D) をリスク支配するのは次が成り立つ場合である。

$$(a-c)(w-x) > (d-b)(z-y)$$

※つまり、自分が均衡からDeviateしたときに、どれだけ痛いか（Payoffを失うか）を表していて、痛いほうがDeviateしないのでより安定的であると考える。

遷移コストの計算とリスク支配均衡の選択

（兎, 兎）からの脱出

全員が兎を狩っている状態から（鹿, 鹿）の吸引域へ移るには、一定数のプレイヤーが鹿に突然変異する必要がある。プレイヤーが兎から鹿に切り替えて得をするには、相手が鹿を狩る確率が 2/3 より大きいと信じる必要がある。

→ 集団の 2/3 超が同時に鹿へ突然変異しなければならない。

（鹿, 鹿）からの脱出

逆に（鹿, 鹿）から脱出するには、プレイヤーが兎を選ぶよう仕向ける必要がある。プレイヤーは相手が兎を狩る確率が 1/3 より大きいと信じれば兎に切り替える。

→ 集団の 1/3 が同時に突然変異するだけでよい。

脱出コストは（鹿, 鹿）が 1/3、（兎, 兎）が 2/3。リスク支配均衡（兎, 兎）の吸引域の方が大きく、抜け出しにくい。SSE は脱出コストが最も高い状態と定義されるから、長期的に社会は（兎, 兎）で最も多くの時間を過ごす。

KMR は、リスク支配均衡がもつ安定性の進化的基礎を説明した。

Young (1993)：交渉ゲームと社会的慣習

Young (1993) は同様の進化過程を交渉ゲームの文脈で分析した。Nash Demand Gameにおける確率進化の長期均衡を分析。長期的に定着する**社会的慣習**は、公理的なナッシュ交渉解(Nash bargaining solution)が予測するものに収束する。

慣習と抵抗(resistance)

地主と小作人のような2つのグループが余剰の分配を交渉する状況を考える。7:3 の分割、5:5 の分割など、さまざまな分配ルールが社会的「慣習」として存在しうる。

慣習の「抵抗」とは、社会をその慣習から別の慣習へ移すのに必要な誤りの最小数と定義される。

最も頑健な慣習の選択

プレイヤーは基本的に過去の慣習に従うが、小さな確率で誤りを犯す。抵抗の高い慣習は誤りに対して頑健で、覆されにくい。進化過程では、最も抵抗の高い慣習が長期的に「安定的慣習」として選ばれる。

Young の中心的発見：最も抵抗の高い慣習は、ナッシュ交渉解にちょうど対応する。ナッシュ交渉解とはプレイヤーの効用の積（ナッシュ積）を最大化する配分であり、まさにこの配分が誤りに対して最も頑健であることが示される。

Session 3-2 のまとめ

1．強化学習は自分の経験だけを見て、高い利得をもたらした戦略の魅力度を高める。信念学習（仮想プレー）は相手の履歴から信念を作り、最適反応を取る。EWA は両者を統合する。

2．公共財ゲームの Restart 効果は、人が学んでいるのはゲームの抽象的構造ではなく、文脈固有の要因（グループの規範・相手のタイプ）であることを示唆する。

3．確率的進化ゲームは、まれな突然変異を導入することで長期的にどの均衡が生き残るかを予測する。KMR はリスク支配均衡が、Young はナッシュ交渉解が選ばれることを示した。

次回(Session 4)：第3章へ。リスク下の意思決定と期待効用理論の限界。